

JUAN BRAIAN HERNÁNDEZ MORANI

INGENIERO DE IA | DESARROLLADOR FULL STACK | LLM, RAG Y SISTEMAS DE AGENTES

Mar del Plata, Buenos Aires, Argentina | +54 9 351 251-3177 | juanbhm.dev@gmail.com
portfolio-juanbhm-dev.vercel.app | github.com/JuanHernandezMorani

PERFIL

Ingeniero de IA y desarrollador full stack que construye sistemas de IA local-first y de ingeniería de software. Creador de SupporterAI Core v1.0-Alpha, que integra inferencia local de LLM, RAG híbrido, memoria vectorial, orquestación de herramientas/MCP, estado persistente de proyectos y validación basada en evidencia. Sólido dominio de Python, JavaScript/TypeScript, Java, C#, SQL e inglés nivel C1.

EXPERIENCIA EN PROYECTOS INDEPENDIENTES

SupporterAI - Ingeniero de IA / Desarrollador Full Stack | 2025 - Presente | I+D privado

- Construyo un entorno de trabajo de IA local-first con Python/FastAPI, JavaFX, runtimes GGUF/llama.cpp, RAG/memoria respaldados por Qdrant e integraciones MCP/JSON-RPC.
- Desarrollo recuperación semántica y léxica híbrida con embeddings, reranking, poda de contexto, memoria de proyecto a largo plazo, planificación/replanificación y orquestación de más de 80 herramientas y capacidades registradas.
- Valido flujos autónomos de ingeniería mediante 7/7 etapas canónicas, cubriendo ejecución real de modelos locales, expansión de herramientas, corrección supervisada, recuperación tras reinicios, checkpoints, tests, diffs y continuación persistente.

SAltron - Investigación de Sistemas de Modelos Multimodales | 2026 - Presente | I+D privado

- Diseño y valido una arquitectura multimodal local-first que abarca 3 sistemas principales del modelo: cognición, percepción/modelado del mundo y generación, coordinados mediante enrutamiento asíncrono, verificación y ejecución consciente de recursos.
- Completé 2 experimentos de model merging con TIES sobre H0 basado en Nemotron y H1 basado en Qwen, preservando el comportamiento lógico esperado en ambos candidatos y la operación multimodal en H0, con validación causal/runtime mediante checkpoints y rutas de ejecución llama.cpp/Vulkan.

Proyectos seleccionados de Ingeniería de Software e IA | 2023 - Presente

- OverhaulCrafter: construí un plugin unificado C#/Unity/BepInEx/Harmony para The Planet Crafter que integra sistemas RPG, QoL, NPC y quests; el build release actual compila con 0 warnings y 0 errors; múltiples flujos fueron validados in-game.
- ZombiesDeOP7DtD: desarrollé sistemas de percepción y diagnóstico en C#/Harmony mediante análisis de código y decompilación, incluyendo línea de visión física, oclusión de audio y evidencia determinística de runtime.
- Otros trabajos públicos incluyen Storefront Change Guard (revisión de código local con llama.cpp), entrenamiento YOLOv11 dual-head, el paquete PyHelper publicado en PyPI y aplicaciones con React/Next.js/Node/PostgreSQL.

HABILIDADES TÉCNICAS

IA / LLM: RAG, embeddings, Qdrant/bases vectoriales, recuperación semántica + léxica, reranking, LLM locales (llama.cpp/GGUF), orquestación de agentes/herramientas, MCP.

ML / Datos: Machine Learning, Deep Learning, PyTorch, PySpark, NumPy, Pandas, análisis estadístico.

Backend: Python, FastAPI, Node.js, Express, APIs REST, OAuth/JWT, SQL, PostgreSQL, MySQL.

Frontend: JavaScript, TypeScript, React, Next.js, HTML5, CSS3.

Ingeniería: Java, C#, Git/GitHub, CI/CD, Linux/WSL2, testing automatizado, ingeniería inversa/decompilación, Unity, Harmony, BepInEx.

Idiomas: Español (nativo), inglés (C1 - EF SET).

FORMACIÓN Y CERTIFICACIONES

AYI Academy - IA y Big Data (ago 2025 - nov 2025): LLM, Machine Learning y Deep Learning | Certificado

Egg LXP - Desarrollador Backend (mar 2023 - dic 2023) | **SoyHenry - Desarrollador Full Stack PERN** (may 2022 - oct 2022) | Certificado

EF SET - Certificado de inglés C1 | Credencial